ТЕХНОСФЕРА

Лекция №2

Распределенная файловая система HDFS

Евгений Чернов

Архитектура HDFS
(Hadoop Distributed File System)

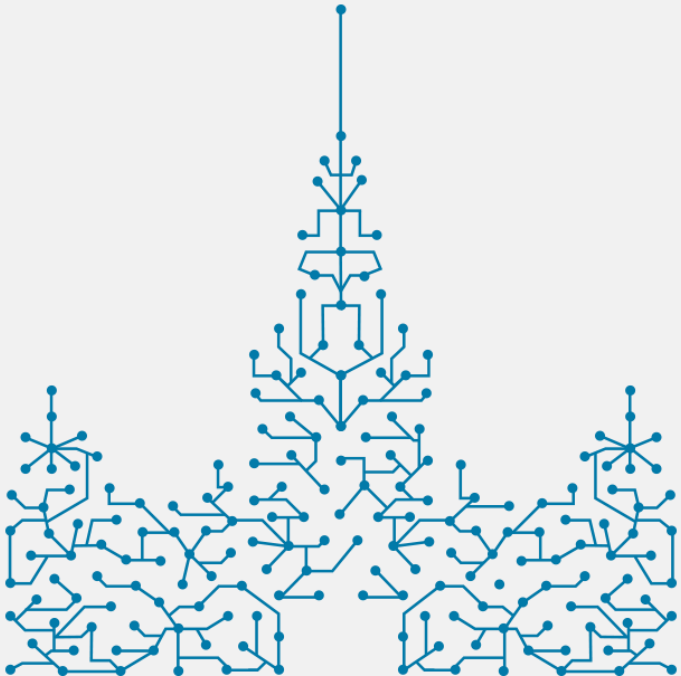

HDFS

Google's Filesystem GFS

research.google.com/archive/gfs-sosp2003.pdf

HDFS

- Работает на кластере серверов
- Для пользователя как “*один большой диск*”
- Работает поверх обычных файловых систем
  (Ext3, Ext4, XFS)

Fault Tolerant

Данные не теряются, если выходят из строя диски или сервера

Используется обычное “железо”

“Дешевое”серверное оборудование

- **Нет** суперкомпьютерам!
- **Нет** десктопам!
- **Да** обычным (~~ненадежным~~) серверам!

HDFS хорошо подходит для…

Хранения больших файлов

- Терабайты, петабайты…
- Миллионы (но не миллиарды) файлов
- Файлы размером от 100 Мб

HDFS хорошо подходит для…

Стриминг данных

- Паттерн “write once / read-many times”
- Оптимизация под последовательное чтение
  - Нет операциям произвольного чтения
- Операция *append* появилась в Hadoop 0.21

HDFS хорошо подходит для…

Обычные сервера

- Менее надежные, чем суперкомпьютеры

HDFS не подходит для…

Low-latency reads

- Высокая пропускная способность вместо быстрого доступа к данным
- HBase помогает решать эту задачу

HDFS не подходит для…

Большое количество небольших файлов

- Лучше миллион больших файлов, чем миллиард маленьких

Лучше 1000 по 1 Гб, чем 100 000 по 10 Мб

HDFS не подходит для…

Многопоточная запись

- Один процесс записи на файл
- Данные дописываются в конец файла

Нет поддержки записи по смещению

Демоны HDFS

Демоны HDFS

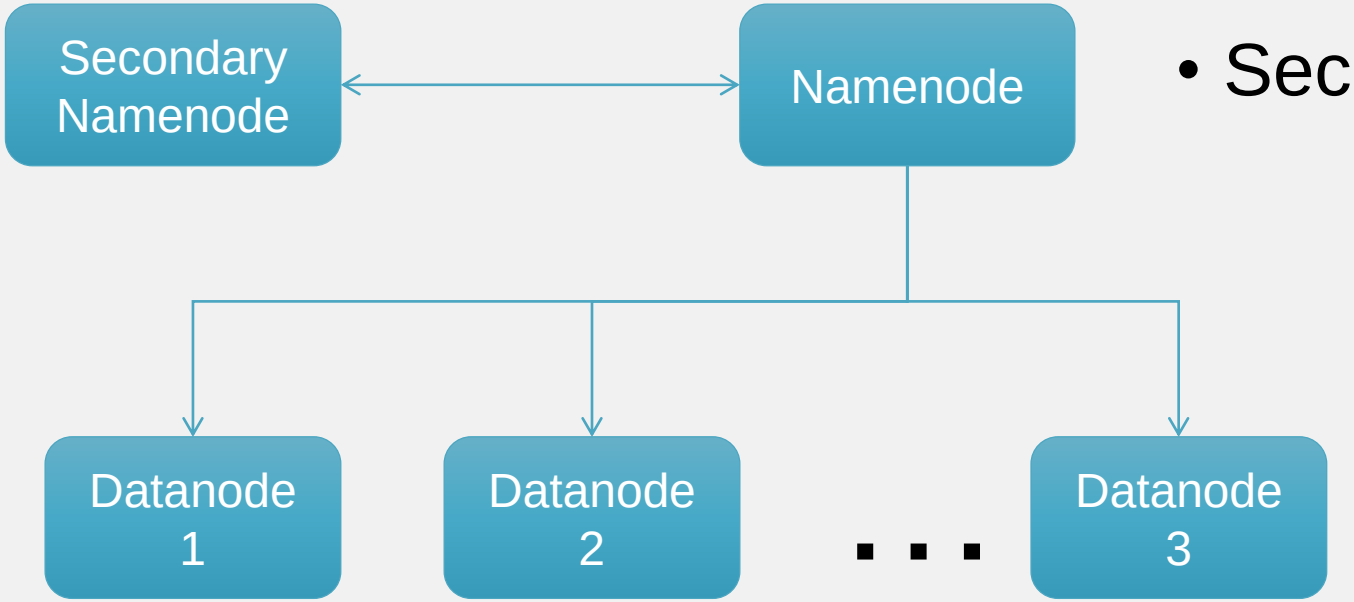

- Namenode
- Datanode
- Secondary node

NameNode

- Отвечает за:
  - файловое пространство (namespace)
  - мета-иформацию
  - расположение блоков файлов
- Запускается на 1й (выделенной) машине

DataNode

- Хранит и отдает блоки данных
- Отправляет ответы о состоянии на Namenode
- Запускается на каждой машине кластера

Secondary Namenode

- Периодически обновляет fsimage
- Требует то же железо, что и Namenode
- (!) Не используется для high-availability, т.е. это не backup для Namenode

Файлы и блоки

- Файлы в HDFS состоят из блоков
  - Блок – единица хранения данных
- Управляется через Namenode
- Хранится на Datanode

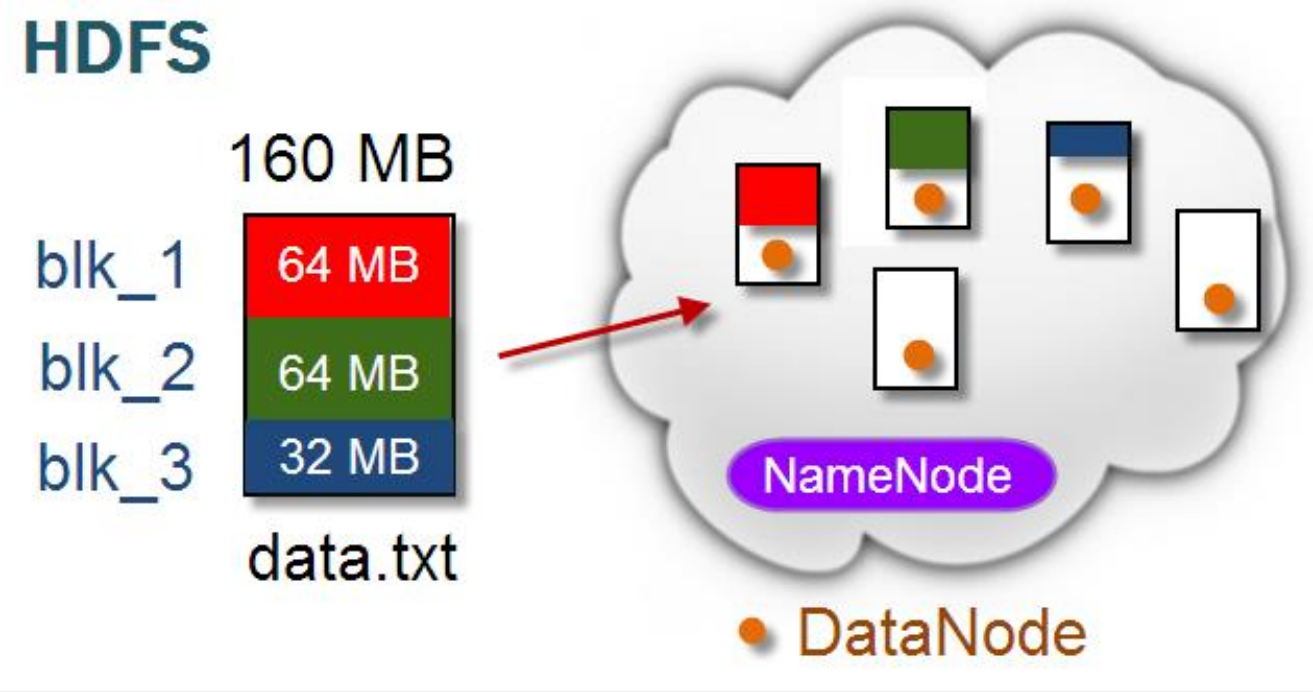

Файлы и блоки

Блок реплицируются по машинам в процессе записи

- Один и тот же блок хранится на нескольких Datanode
- Фактор репликации по умолчанию равен **3**

large_file.txt = block 1 + block 2

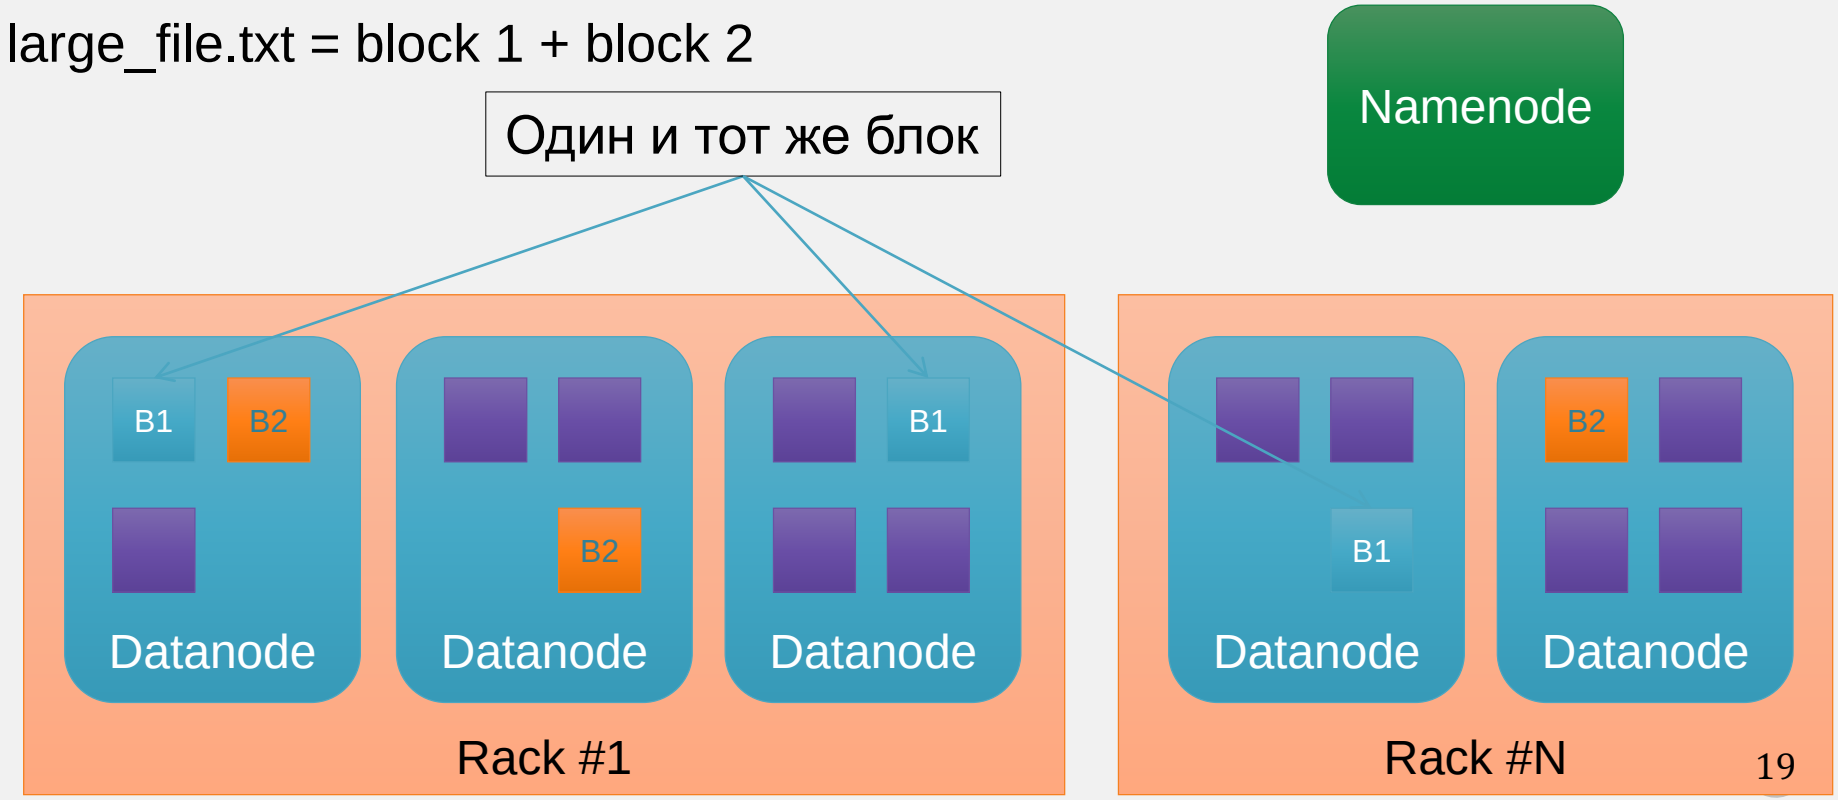

Размер блоков в HDFS

- Стандартный размер блоков 64Мб или 128Мб
- Основной мотив этого – снизить стоимость *seek time* по сравнению со скоростью передачи данных (*transfer rate*)
  - 'Time to transfer' > 'Time to seek'
- Например, пусть будет
  - seek time = 10ms
  - transfer rate = 100 MB/s
- Для достижения *seek time* равного 1% от *transfer rate* размер блока должен быть 100Мб

Задача

Какой должен быть размер блока, чтобы seek time составлял 1,5% от transfer time, если:

- seek time = 20 мс
- transfer rate = 48 МБ/с

Репликация блоков

- Namenode определяет, куда копировать реплики блоков
- Размещение блоков зависит от того, в какой стойке стоит сервер (*rack aware*)
  - Баланс между надежностью и производительностью
    - Попытка снизить нагрузку на сеть (*bandwidth*)
    - Попытка улучшить надежность путем размещения реплик в разных стойках
  - Фактор репликации по умолчанию равен 3
    - 1-я реплика на локальную машину
    - 2-я реплика на другую машину из той же стойки
    - 3-я реплика на машину из другой стойки

Клиенты, Namenode и Datanodes

- Namenode не выполняет непосредственно операций чтения/записи данных
  - Это одна из причин масштабируемости Hadoop
- Клиент обращается к Namenode для
  - обновления неймспейса HDFS
  - для получения информации о размещении блоков для чтения/записи
- Клиент взаимодействует напрямую с Datanode для чтения/записи данных

HDFS: чтение файла

1. Получить расположение блоков
2. Выбрать “ближайший” Datanode для 1 блока
3. Прочитать 1й блок файла
4. Выбрать “ближайший” Datanode для 2 блока
5. Прочитать 2й блок файла
6. …..
7. Закрыть соединение

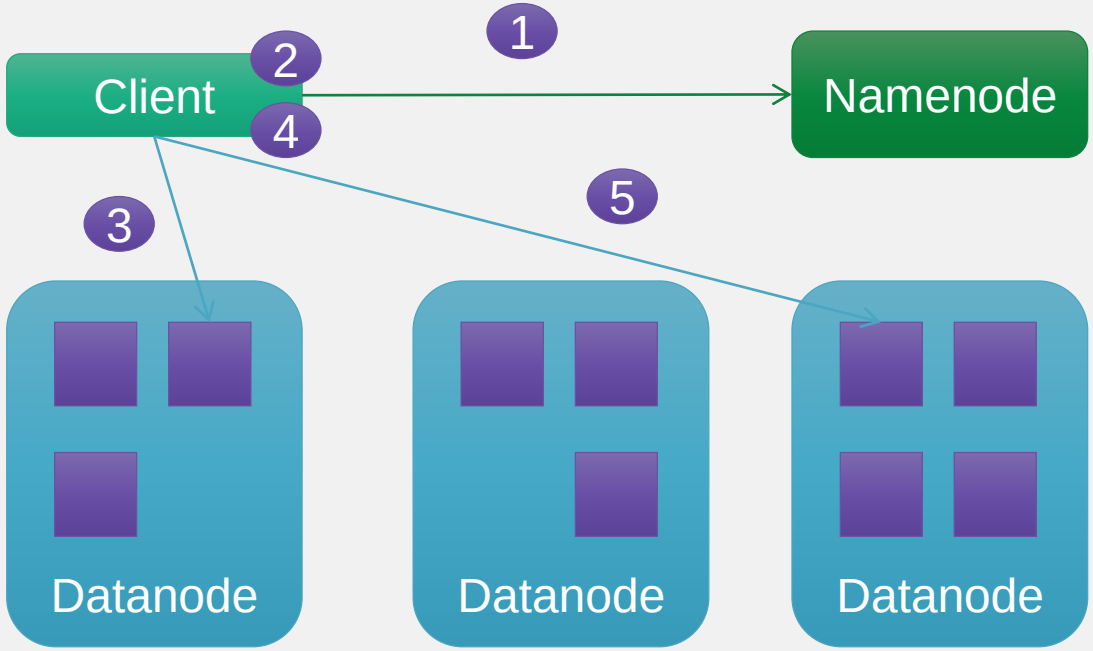

Важно: передача данных происходит без участия NameNode

HDFS: ошибки при чтении файла

1. Поломка Datanode:
   - Читаем блок с другой Datanode
   - Запоминаем сломанный
2. Неправильная чексумма:
   - Сообщаем NameNode о сломанном блоке
   - Читаем другую реплику блока

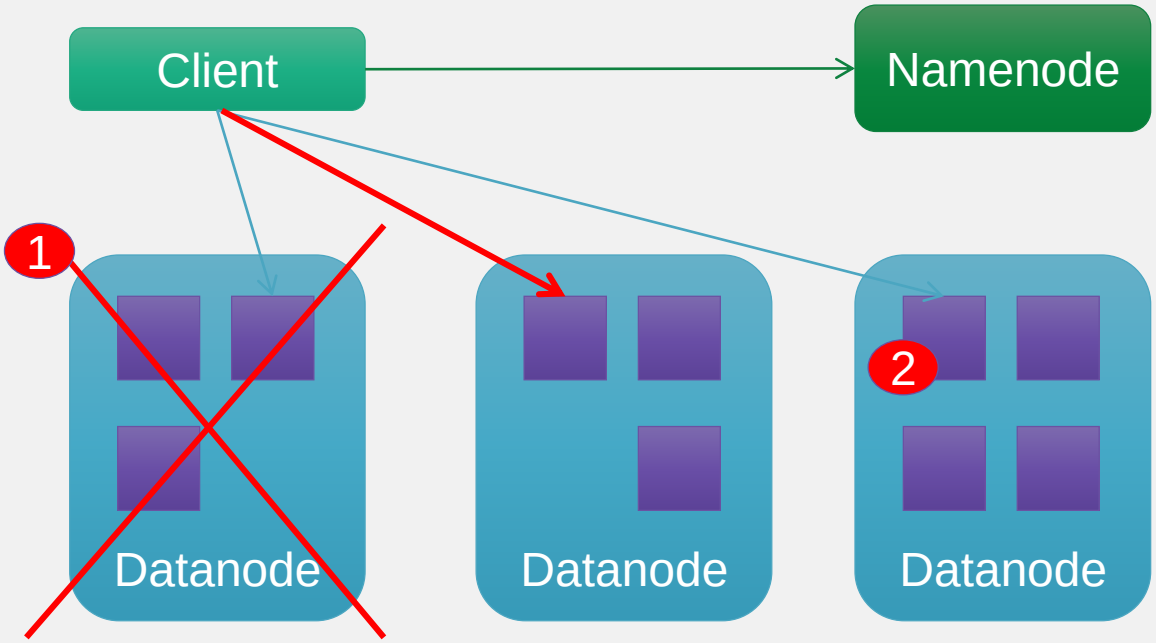

Расстояние до блоков

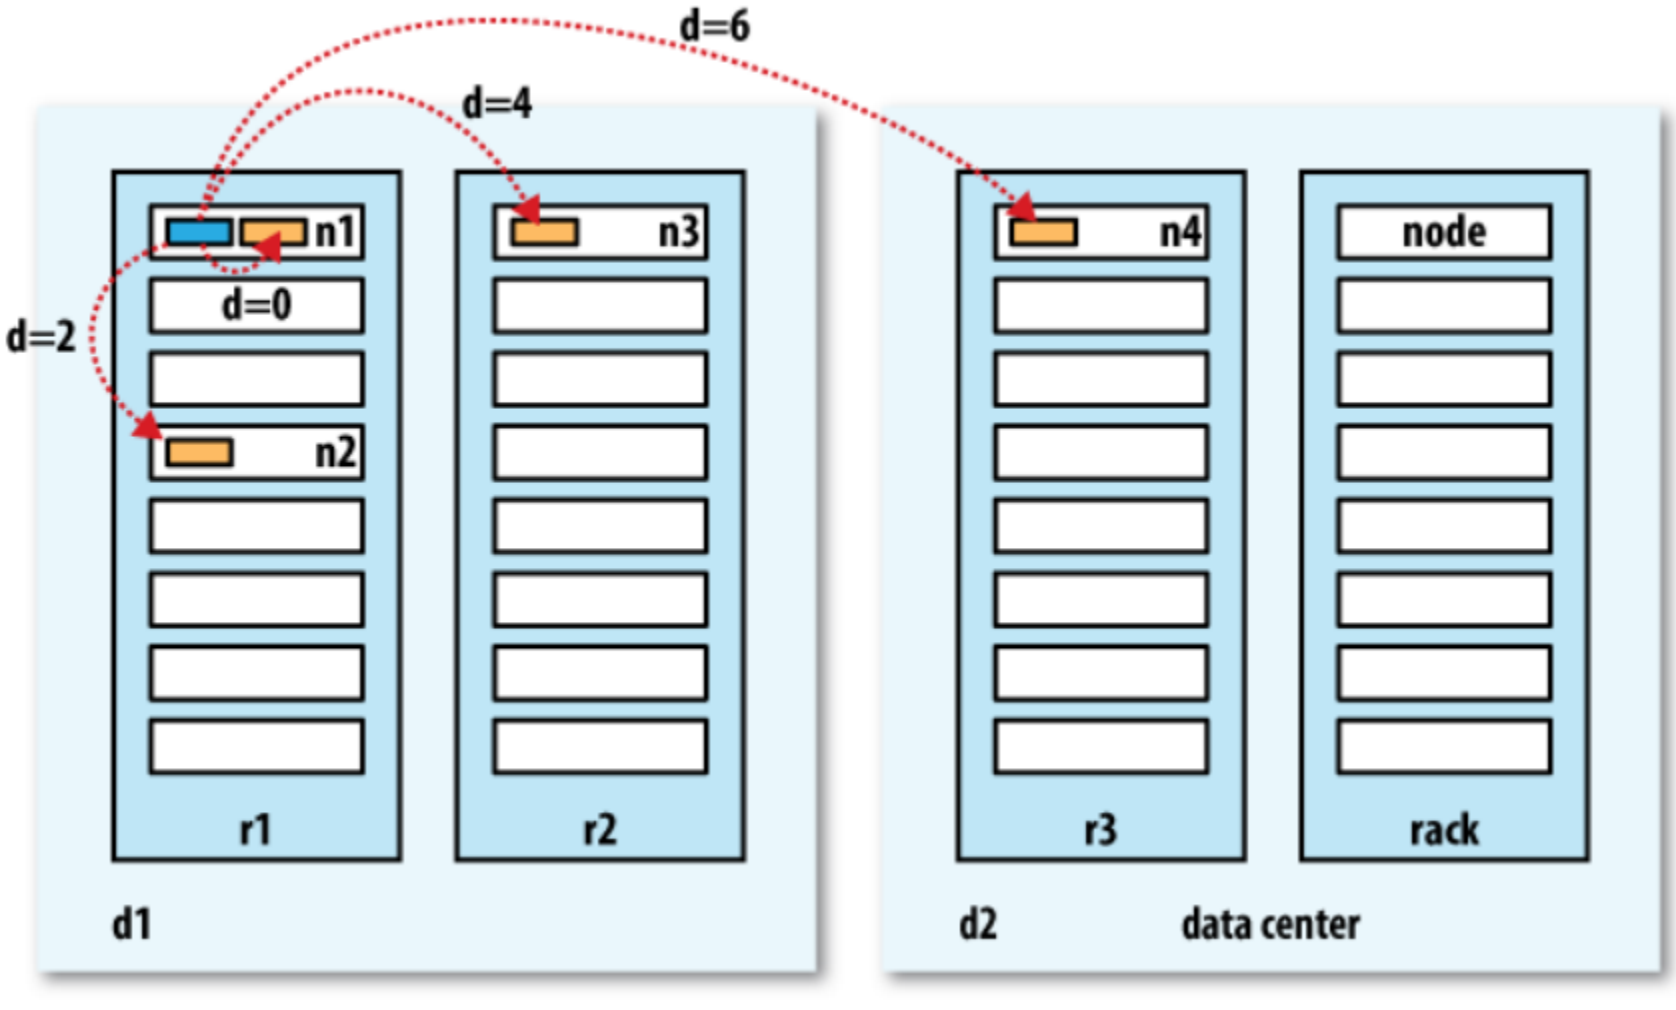

HDFS: запись файла

1. Сообщаем NN о создании файла:
   - проверка существования
   - проверка прав доступа
   - создание записи о файле
2. Запрашиваем расположение 1-го блока у NN:
   - получаем список DN
   - DN образую pipeline
3. Начинаем писать данные на 1-ю DN
4. 1-я DN сохраняет данные и отправляет их на 2-ю DN
5. 2-я DN сохраняет данные и отправляет их на 3-ю DN
6. Подтверждение записи

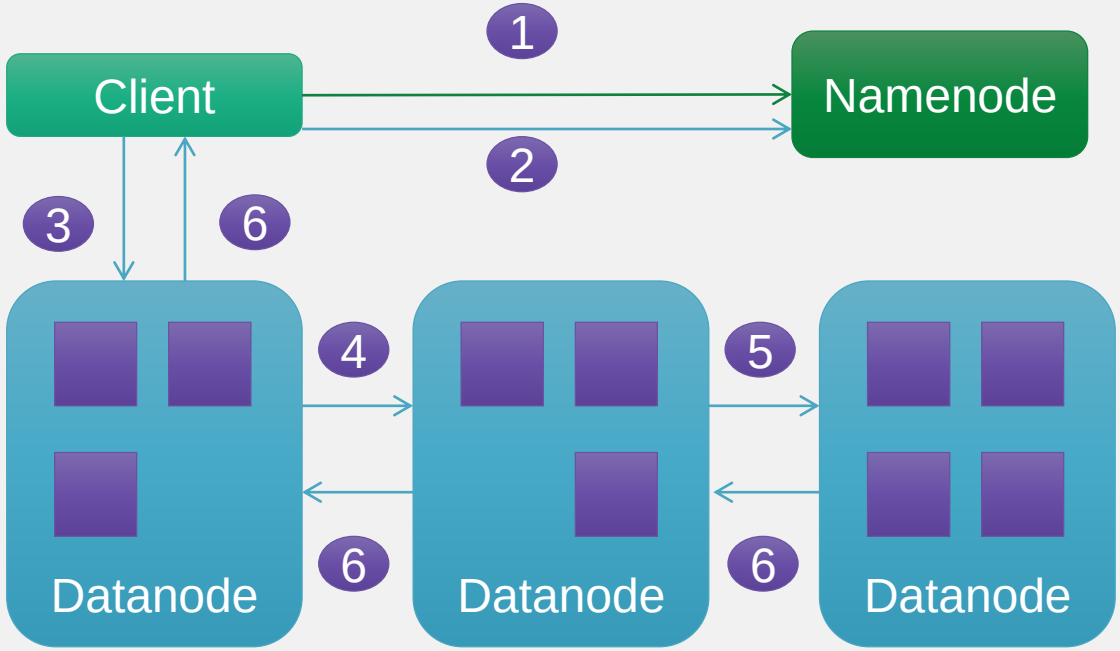

Внимание: данные между DataNode передается пачками по 4 Кб

HDFS: ошибки при записи файла

1. Падение DataNode:
   - не до конца записанные данные не теряются
   - DataNode исключается из pipeline
   - данные пишутся на оставшиеся DN
   - блок становится недореплицированным
   - меняется идентификатор блока
2. Могут упасть несколько DN
3. Если есть хотя бы одна копия, то запись считается успешной

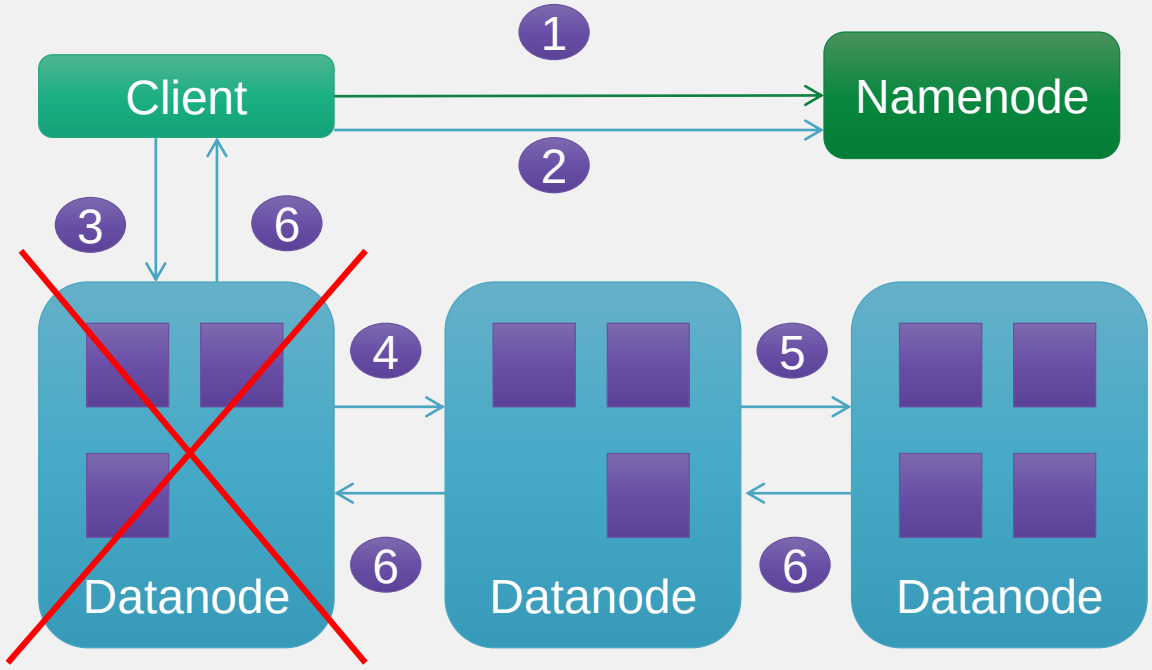

Namenode: использование памяти

Для быстрого доступа вся мета-информация о блоках хранится в ОЗУ Namenode

- Чем больше кластер, тем больше ОЗУ требуется

- Лучше миллионы больших файлов, чем миллиарды маленьких
- Работает на кластерах из сотен машин

Namenode: использование памяти

Как влияет размер блока на максимальный размер FS?

- Больше размер блока –> меньше блоков
- Меньше блоков –> больше файлов в FS

Namenode: использование памяти

- Пусть у нас есть 200Тб = 209,715,200 Мб
- При размере блока 64Мб:

  209,715,200Мб / 64Мб = 3,276,800 блоков
- При размере блока 128Мб:

  209,715,200Мб / 128Мб = 1,638,400 блоков

Namenode: использование памяти

Hadoop 2+

- Namenode Federation
  - Каждая Namenode управляет частью блоков
  - Горизонтальное масштабирование Namenode
- Поддержка кластеров из тысячи машин
- Детали: http://hadoop.apache.org/docs/r2.0.2-alpha/hadoop-yarn/hadoop-yarn-site/Federation.html

Fault-tolerance в Namenode

- Если Namenode падает, то HDFS не работает
- Namenode – это единая точка отказа (*single point of failure*)
  - Должна работать на отдельной надежной машине
  - Обычно, это не бывает проблемой

Fault-tolerance в Namenode

Hadoop 2+

- High Availability Namenode
  - Процесс Active Standby всегда запущен и берет на себя управления в случае падения Namenode
  - Все еще в процессе тестирования
- Более подробно тут:
  - http://hadoop.apache.org/docs/r2.0.2-alpha/hadoop-yarn/hadoop-yarn-site/HDFSHighAvailability.html

Доступ к HDFS

- Способы доступа
  - Direct Access
    - Взаимодействует с HDFS с помощью нативного клиента
    - Java, C++
  - Через Proxy Server
    - Доступ к HDFS через Proxy Server – middle man
    - Серверы REST, Thrift и Avro

Direct Access

- API для Java и C++
- Клиент запрашивает метаданные от NN
- Клиент напрямую запрашивает данные от DN
- Используется для MapReduce

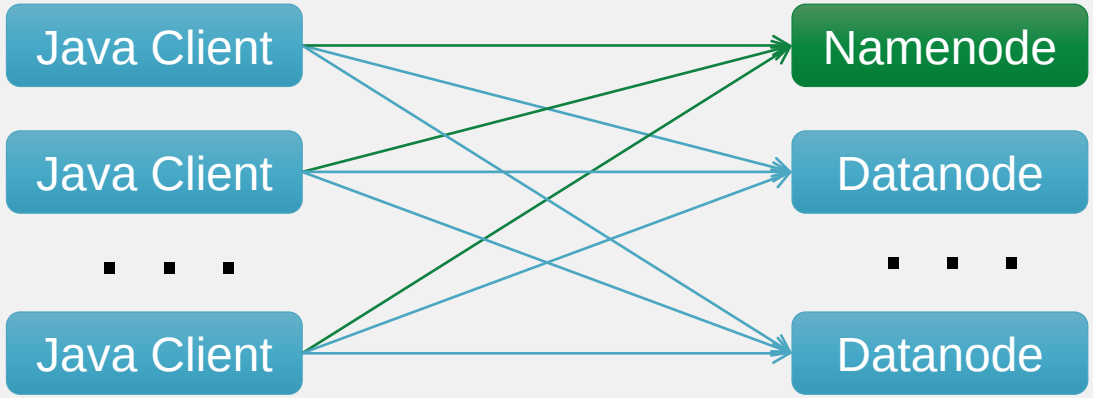

Доступ через Proxy Server

- Клиент работает через внешний Proxy Server
- Существует несколько серверов в поставке с Hadoop
  - Thrift – язык определения интерфейса
  - WebHDFS REST – ответы в формате JSON, XML или Protocol Buffers
  - Avro – механизм сериализации

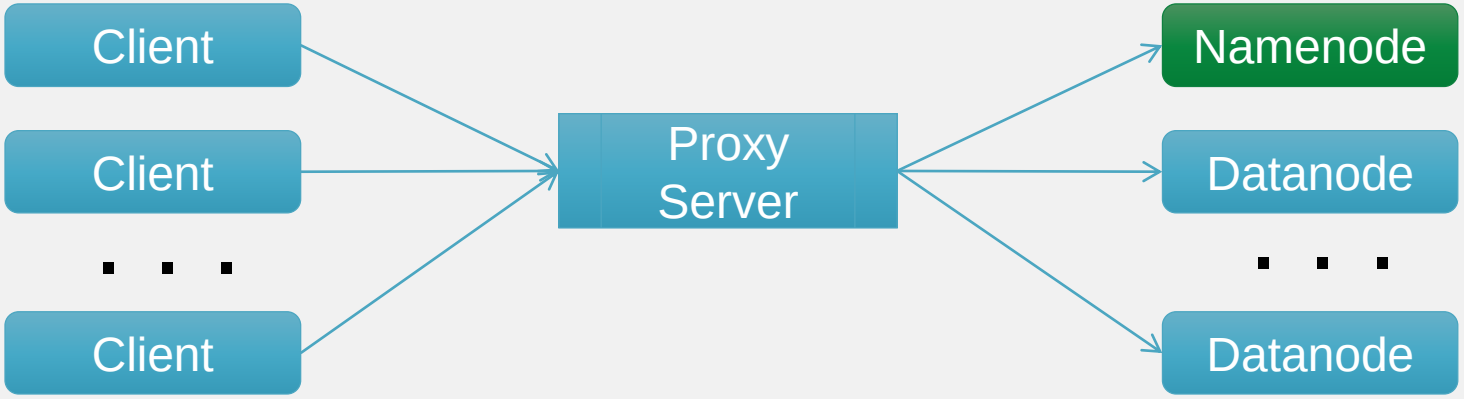

HDFS Shell

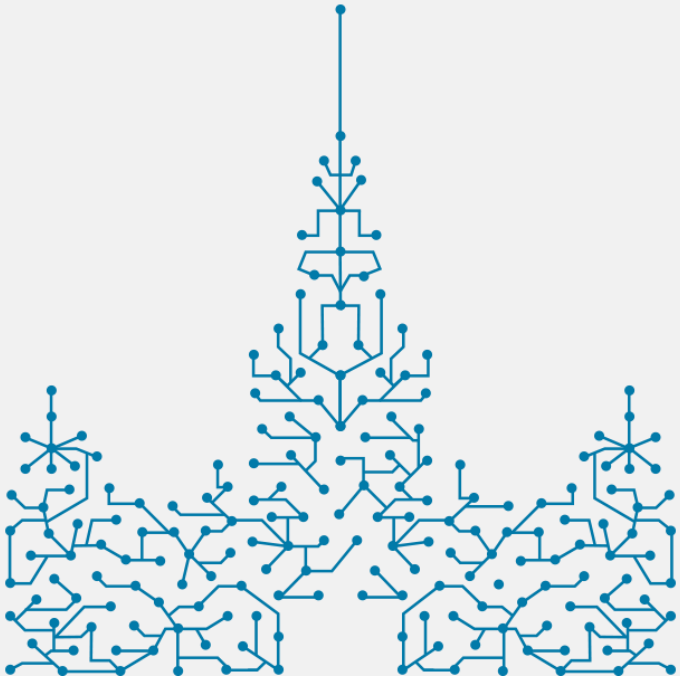

Команды Shell

$hdfs dfs -<command> -<option> <URI>

$hdfs dfs –ls /

URI (*Uniform Resource Identifier*)

hdfs://localhost:8020/user/home

scheme authority HDFS path

Примеры URI

- Local:

  $hdfs dfs -ls file:///to/path/file3

- HDFS:

  $hdfs dfs -ls hdfs://localhost/to/path/dir

- fs.default.name=hdfs://localhost

  $hdfs dfs -ls /to/path/dir

Команды в shell

- Большинство команд ведет себя схожим образом, что и команды в Unix
  - *cat, rm, ls, du …*
- Поддержка специфичных для HDFS операций
  - setrep - смена фактора репликации
- Вывод списка команд
  - *$ hdfs dfs –help*
- Показать детальную информацию по команде
  - *$ hdfs dfs -help <command_name>*

Основные команды в shell

ls – листинг директории и статистика файлов

```
[cloudera@localhost ~]$ hdfs dfs -ls /user/cloudera/wordcount/output
Found 3 items
-rw-r--r--     3 cloudera cloudera    0 2014-03-15 11:56
/user/cloudera/wordcount/output/_SUCCESS
drwxr-xr-x   - cloudera cloudera    0 2014-03-15 11:56
/user/cloudera/wordcount/output/_logs
-rw-r--r--     3 cloudera cloudera  31 2014-03-15 11:56
/user/cloudera/wordcount/output/part-00000
```

Основные команды в shell

mkdir – создать директорию

*$hdfs dfs –**mkdir** /data/new_path*

Чтение файлов в shell

cat – вывод источника в stdout

- Весь файл: *$hdfs dfs -**cat** /dir/file.txt*
- Полезно вывод перенаправить через pipe в *less, head, tail* и т.д.
- Получить первые 100 строк из файла:

*$hdfs dfs -**cat** /dir/file.txt* | *head -n 100*

Чтение файлов в shell

text – аналог **cat**, но разархивирует архивы:

*$hdfs dfs -**cat** /dir/file.gz – непонятный текст*

*$hdfs dfs -**text** /dir/file.gz – понятный текст*

*$hdfs dfs -**cat** /dir/file.txt = $hdfs dfs -**text** /dir/file.txt*

tail – выводит последние строчки файла

*$hdfs dfs -**cat** /dir/file.txt | tail – плохо*

*$hdfs dfs -**tail** /dir/file.txt – хорошо*

Копирование данных в shell

cp **–** скопировать файлы из одного места в другое

*$hdfs dfs -**cp** /dir/file1 /otherDir/file2*

! годится только для небольших файлов

distcp **–** копирует большие файлы или много файлов

*$hadoop **distcp** /dir/file1 /otherDir/file2*

Копирование данных в shell

- ***mv*** – перемещение файла из одного места в другое
  - *$hdfs dfs -mv /dir/file1 /dir2*
- ***put* (*copyFromLocal)*** – копирование файла из локальной FS в HDFS
  - *$hdfs dfs -put localfile /dir/file1*
  - *copyFromLocal*
- ***get (copyToLocal)*** – копирование файла из HDFS в локальную FS
  - *$hdfs dfs -get /dir/file1 localfile*
  - *copyToLocal*

Удаление и статистика в shell

- ***rm*** **–** удалить файл (в корзину)
  - *$hdfs dfs -rm /dir/file*
- ***rm -r*** **–** удалить рекурсивно директорию
  - *$hdfs dfs -rm -r /dir*

Статистика в shell

du **–** размер файла или директории в байтах

*$hdfs dfs -**du** /dir/*

du -h **–** размер файла или директории в удобно-читаемом формате

*$hdfs dfs -**du** –**h** /dir/*
65M /dir

Остальные команды в shell

- Другие команды
  - *chmod, chown, count, test и т.д.*
- Чтобы узнать больше
  - *$hdfs dfs* ***-help***
  - *$hdfs dfs* ***-help <command>***

Команда fsck

- Проверка неконсистентности файловой системы
- Показывает проблемы
  - Отсутствующие блоки
  - Недореплицированные блоки
- Не устраняет проблем, только информация
  - Namenode попытается автоматически исправить проблемы
- **$ hdfs fsck <path>**
  - *$ hdfs fsck /*
- Выводит информацию о файлах и блоках:
  - *$ hdfs fsck / -files -blocks*

Права в HDFS

- Ограничения на уровне файла/директории
  - Сходство с моделью прав в POSIX
  - Read (r), Write (w) и Execute (x)
  - Разделяется на пользователя, группу и всех остальных
- Права пользователя определяются исходя из прав той ОС, где он запускает клиентское приложение
- Авторизация через Kerberos
  - Hadoop 0.20.20+
  - http://hadoop.apache.org/common/docs/r0.23.0/hadoop-yarn/hadoop-yarnsite/ClusterSetup.html

Права в HDFS

```
[cloudera@localhost ~]$ hadoop fs -ls /user/cloudera/wordcount/output
Found 3 items
-rw-r--r--     3 cloudera cloudera    0 2014-03-15 11:56
/user/cloudera/wordcount/output/_SUCCESS
drwxr-xr-x   - cloudera cloudera    0 2014-03-15 11:56
/user/cloudera/wordcount/output/_logs
-rw-r--r--     3 cloudera cloudera  31 2014-03-15 11:56
/user/cloudera/wordcount/output/part-00000
```

Команда DFSAdmin

- Команды для администрирования HDFS
  - *$hdfs dfsadmin <command>*
  - Напр.: *$hdfs dfsadmin –report*
- ***report*** – отображает статистику по HDFS
  - Часть из этого также доступна в веб-интерфейсе
- ***safemode*** – переключения между режимом safemode для проведения административных работ
  - Upgrade, backup и т.д.

Балансер HDFS

- Блоки в HDFS могут быть неравномерно распределены по всем Datanode’ам кластера
- Балансер – это утилита, которая автоматически анализирует расположение блоков в HDFS и старается его сбалансировать
  - *$ hdfs **balancer***

Задание

1. Создать локально файл test.txt размером 100Мб
2. Создать hdfs-директории temp и logs
3. Записать файл test.txt в директорию temp
4. Посмотреть свойства записанного файла
5. Переместить файл test.txt в директорию logs
6. Установить фактор репликации для файла равным 2
7. Скопировать test.txt в test2.txt
8. Скопировать директорию logs в logs2 с помощью distcp
9. Посмотреть размер всех директорий в ./
10. Удалить директорию logs2
11. Запустить fsck на директории logs
12. Посмотреть отчет о HDFS через dfsadmin

HDFS API

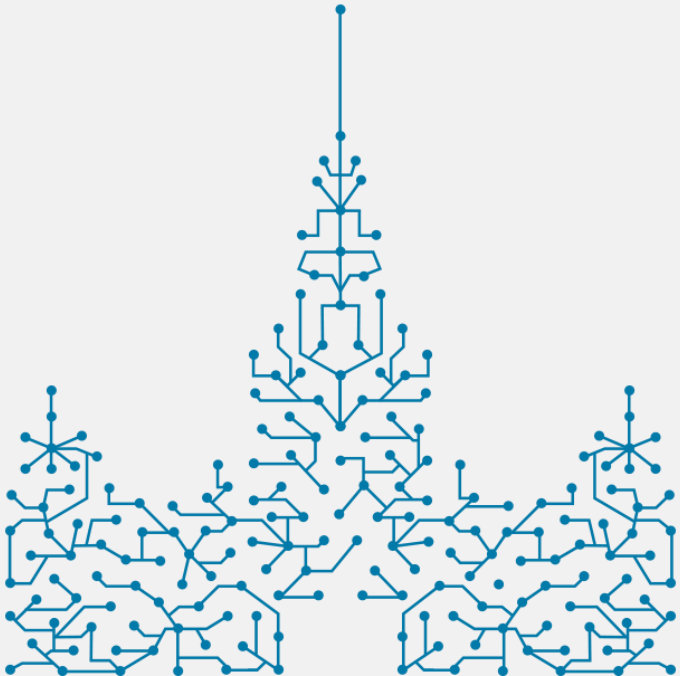

File System Java API

- org.apache.hadoop.fs.FileSystem
  - Абстрактный класс, которые представляет абстрактную файловую систему
  - (!) Это именно класс, а не интерфейс
- Реализуется в различных вариантах
  - Напр., локальная или распределенная

Реализации *FileSystem*

- Hadoop предоставляет несколько конкретных реализаций
  - *org.apache.hadoop.fs.LocalFileSystem*
    - Подходит для нативных FS, использующих локальные диски
  - *org.apache.hadoop.hdfs.DistributedFileSystem*
    - Hadoop Distributed File System (HDFS)
  - *org.apache.hadoop.hdfs.HftpFileSystem*
    - Доступ к HDFS в read-only режиме через HTTP
  - *org.apache.hadoop.fs.ftp.FTPFileSystem*
    - Файловая система поверх FTP-сервера
- Различные реализации для разных задач

Пример SimpleLocals.java

```
public class SimpleLocalLs {
    public static void main(String[] args) throws Exception{

        Path path = new Path("/");
        if ( args.length == 1 ){
            path = new Path(args[0]);
        }

        Configuration conf = new Configuration();
        FileSystem fs = FileSystem.get(conf);

        FileStatus [] files = fs.listStatus(path);
        for (FileStatus file : files ){
            System.out.println(file.getPath().getName());
        }
    }
}
```

FileSystem API: Path

- Объект Path представляет файл или директорию
  - *java.io.File* сильно завязан на локальную FS
- Path – это на самом деле URI в FS
  - HDFS: hdfs://localhost/user/file1
  - Local: file:///user/file1

```
new Path("/test/file1.txt");
new Path("hdfs://localhost:9000/test/");
```

Объект Configuration

- Объект Configuration хранит конфигурацию сервера и клиента
- Использует простую парадигму key-value
- Получения значения параметра:

```
String name = conf.get("fs.default.name");
String name = conf.get("fs.default.name“, “hdfs://localhost:9000”);
float size = conf.getFloat("file.size");
```

Чтение данных из файла

- Создать объект ***FileSystem***
- Открыть ***InputStream***, указывающий на ***Path***
- Скопировать данные по байтам используя ***IOUtils***
- Закрыть ***InputStream***

Пример ReadFile.java

```
public class ReadFile {
    public static void main(String[] args) throws
                                                IOException {
        Path file = new Path("/path/to/file.txt");
        FileSystem fs = FileSystem.get(new
                    Configuration()); // Open FileSystem

        InputStream input = null;
        try {
            input = fs.open(file); // Open InputStream
            // Copy from Input to Output Stream
            IOUtils.copyBytes(input, System.out, 4096);
        } finally {
            IOUtils.closeStream(input); // Close stream
        }
    }
}
```

Запись данных в файл

- Создать объект ***FileSystem***
- Открыть ***OutputStream***
  - Указывает на ***Path*** из ***FileSystem***
  - Используем ***FSDataOutputStream***
  - Автоматически создаются все директори в пути, если не существуют
- Копируем данные по байтам используя ***IOUtils***

Пример WriteToFile.java

```
public class WriteToFile {
    public static void main(String[] args) throws
       IOException {
        String text = "Hello world in HDFS!\n";
        InputStream in = new BufferedInputStream(
              new ByteArrayInputStream(text.getBytes()));

        Path file = new Path("/path/to/file.txt");
        Configuration conf = new Configuration();
        // Create FileSystem
        FileSystem fs = FileSystem.get(conf);
        // Open OutputStream
        FSDataOutputStream out = fs.create(file);
        IOUtils.copyBytes(in, out, conf); // Copy Data
    }
}
```

FileSystem: запись данных

- ***fs.append(path)*** – дописать к существующему файлу
  - Поддержка для HDFS
- Нельзя записать в середину файла
- ***FileSystem.create(Path)*** создает все промежуточные директории для заданного каталога (по умолчанию)
  - Если это не нужно, то надо использовать
    - *public FSDataOutputStream create(Path f, boolean overwrite)*
    - *overwrite = false*

FileSystem: подстановки (globbing)

- ***FileSystem*** имеет поддержку матчинга имени файла по заданному паттерну используя метод ***globStatus()***
  - *FileStatus [] files = fs.globStatus(glob);*
- Примеры шаблонов
  - **?** – любой один символ
  - ***** - любые 0 и больше символов
  - **[abc]** – любой символ из набора в скобках
    - [a-z]
  - [^a] – любой символ, кроме указанного
  - {ab,cd} – любая строка из указанных в скобках

Книги

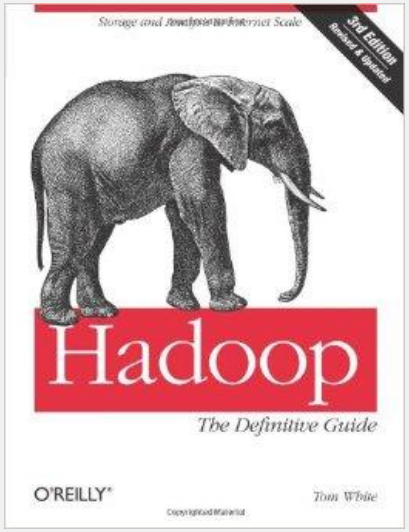

Hadoop: The Definitive Guide
Tom White (Author)
O'Reilly Media; 3rd Edition

Chapter 3: The Hadoop Distributed Filesystem

Chapter 4: Hadoop I/O

ТЕХНОСФЕРА

Отмечайтесь и оставляйте отзыв

Спасибо за внимание!

Чернов Евгений

e.chernov@corp.mail.ru

Задание

- Написать Java-класс CpFile, который осуществляет копирование файла. При этом и источник и место назначения могут располагаться как локально, так и в HDFS

Тестирование:

- Локальный файл **test.txt** копируем в локальный файл **test2.txt** (аналог **cp**):

  $ hadoop jar cpfile.jar org.sfera.CpFile file:///home/cloudera/test.txt file:///home/cloudera/test2.txt

- Локальный **test2.txt** копируем в hdfs файл **test3.txt** (аналог **-put**):

  $ hadoop jar cpfile.jar org.sfera.CpFile file:///home/cloudera/test2.txt test3.txt

- Hdfs файл **test3.txt** копируем в рваы файл **test4.txt** (аналог **–cp**):

  $ hadoop jar cpfile.jar org.sfera.CpFile test3.txt test4.txt

- Hdfs файл **test4.txt** копируем в локальный файл **test5.txt** (аналог **–get**):

  $ hadoop jar cpfile.jar org.sfera.CpFile test4.txt file:///home/cloudera/test5.txt